

4. Logbucheintrag 14/05/25

Ich habe in Freiburg Informatik studiert. Eine interessante Zeit, rückblickend betrachtet. Die Hälfte der Leute dort schien besessen von der Idee, die Welt zu verändern – meist durch irgendeine App, die soziale Interaktionen "optimieren" oder den Pizzalieferprozess revolutionieren sollte. Gewissermaßen haben sie es ja geschafft, nur eben anders als gedacht: über ausgeklügelte AdTech-Algorithmen, die uns in Echokammern sperren, süchtig machende Feeds, die unsere Aufmerksamkeitsspanne zerfressen, und obskure Ranking-Systeme, die Belanglosigkeiten an die Spitze spülen, während Relevantes in der Bedeutungslosigkeit versinkt. Ich habe damals gelächelt über die Ehrgeizigen, die unbedingt zu den großen Namen wollten, zu Meta, zu Google, um dort ihr kleines, gut bezahltes Rädchen im gigantischen Getriebe der globalen Datensammelei und Verhaltensmanipulation zu werden. Jetzt, ironischerweise, verhalte ich mich selbst wie ein Ein-Mann-Konzern im Miniaturformat: Ich baue mir meine eigene verdammte KI, hier in meiner Einzimmerwohnung.

Sieben Tage Funkstille im Logbuch. Nicht, weil nichts passiert wäre – im Gegenteil. Es war die Woche der Maschinen, eine Art digitale Revolution hier im Augustinerhof. Während ich hier Lötstellen prüfte und Kabel zog, arbeitete mein digitaler Vorposten, der Webcrawler, sich unermüdlich und selbstständig durch das Netz. Tag und Nacht. Das Ergebnis liegt jetzt vor mir, oder besser gesagt, es füllt die brandneuen Speicher bis zum Bersten: Rohdaten. Einige Terabytes, grob geschätzt – der genaue Umfang wird sich erst nach der Bereinigung zeigen. Text, Code, Dialogfragmente, wissenschaftliche Paper, Blogposts, Forendiskussionen – der gesamte unstrukturierte, oft widersprüchliche, meist minderwertige Output der menschlichen Zivilisation seit Erfindung des Hyperlinks, eingefangen in einem digitalen Schleppnetz. Ein gigantischer Haufen digitalen Schlamms, der nun darauf wartet, gefiltert, gesiebt und vielleicht, in etwas Wertvolles verwandelt zu werden.

Parallel dazu lief die andere, handfestere Operation: Der Umbau des Kühlschranks zum Server ist abgeschlossen. Im Inneren, wo früher Joghurtbecher und Gemüse ihr Dasein fristeten, surren jetzt leise die Lüfter von 30 potenten Grafikkarten, flankiert von einem Pool aus NVMe-SSDs, die mein gesamtes Erspartes verschlungen haben. Jeder Cent ist jetzt Silizium, Kupfer und schnelles Flash-Memory. Der Kontostand? Sagen wir: eine minimalistische Datenstruktur. Aber die Hardware steht. Sie läuft stabil. Die Temperatur-Logs der verschiedenen Kühlzonen zeigen bisher keine kritischen Werte – die alte Kälte-Infrastruktur scheint der neuen thermischen Last gewachsen zu sein. Nur die notwendigsten Dienste laufen: SSH für den Zugriff, ein rudimentäres Logging. Keine unnötigen Ports offen, keine Discovery-Protokolle. Ein abgeschottetes System in einem isolierten Gehäuse. Kalte Ordnung für heiße Berechnungen.

Natürlich ist der Rohdatensatz allein wertlos, schlimmer noch, er ist gefährlich. Ein Large Language Model ist nur so gut wie der Korpus, auf dem es trainiert wird, und dieser hier ist ein Minenfeld aus Redundanz, Falschinformation und genau jenem allgegenwärtigen KI-Slop, den ich ja eigentlich überwinden will. Die nächsten Schritte sind klar, die Pipeline steht, orientiert an solider Ingenieurskunst: Zuerst rigorose De-Duplizierung mittels Hashing, dann aggressives Filtern – Sprache erkennen (nur Deutsch und Englisch für den Anfang?), Boilerplate-Code von Webseiten entfernen, Spam, Hassrede und offensichtlich

minderwertigen KI-Content identifizieren und rauswerfen (die Ironie schmerzt fast), versuchen, persönliche Informationen bestmöglich zu scrubben (Urheberrecht und Ethik sind ein eigenes Minenfeld, das ich vorerst nur markiere, nicht betrete). Dann die Normalisierung von Unicode, Whitespace und Satzzeichen, gefolgt von der Aufteilung des bereinigten Korpus in handhabbare, gleichmäßig verteilte Shards und schließlich das sorgfältige Markieren von Dokumentgrenzen. Die Verwerfungsquote wird brutal sein, ich rechne mit 80%, vielleicht sogar 90% reinem Müll. Aber was übrig bleibt, sollte... Substanz haben. Die alte Regel gilt: Garbage-In ist Garbage-Out.

Die Infrastruktur läuft also. Der Datenplan steht. Zeit für den ersten echten Schritt der Transformation, den ersten Schnitt durch die rohe Masse der Sprache: Heute beginnt die Tokenisierung. Der Prozess, diesen Ozean aus bereinigtem Text in die diskreten Einheiten zu zerlegen, die das Modell später verarbeiten kann – Wörter, Subwörter, vielleicht sogar einzelne Zeichen – und daraus das Vokabular zu bauen, den Index unserer zukünftigen künstlichen Sprache. Ich habe mich nach Lektüre und einigen Tests für Byte Pair Encoding entschieden; es scheint ein guter Kompromiss zwischen der Größe des Vokabulars und der Fähigkeit zu sein, auch seltene oder neue Wörter durch Zerlegung in Sub-Einheiten zu repräsentieren. Zielgröße: vorerst 32.000 Tokens. Das erscheint mir handhabbar und sollte die Out-of-Vocabulary-Rate/ OOV unter einer kritischen Schwelle halten, vielleicht unter 2%. Die notwendigen Sonderzeichen für Anfang (BOS), Ende (EOS), Padding (PAD) und unbekannte Tokens (UNK) sind definiert. Ich habe das Skript gerade auf dem Kühlschranks-Server gestartet. Man hört, wie die Lüfter leise hochfahren. Die GPUs sind noch still, aber die CPUs arbeiten, wühlen sich durch die ersten Gigabytes des bereinigten Korpus, zählen Byte-Paar-Frequenzen, suchen nach den Mustern, die zu neuen Tokens zusammengefasst werden. Es ist der erste Moment, in dem aus dem Chaos digitale Struktur entsteht. Sprache wird zu Mathematik. Zu Zahlen.

Es wird dauern. Tage, vielleicht eine Woche, bis das Vokabular konvergiert ist und stabil steht. Und wenn alles gut läuft, habe ich in 1-2 Wochen meine eigene Künstliche Intelligenz.

Teufel, ja, ich bin Informatiker! Fürchtet meine Informatiker-Kräfte!