

6. Logbucheintrag 30/05/25

Anke geht nicht ran. Viermal probiert allein gestern. Mailbox. Wahrscheinlich immer noch sauer wegen ihres Geburtstags. Oder einfach nur genervt von meiner wochenlangen Funkstille davor. Verständlich. Aber ändern kann ich's gerade auch nicht.

Nächste Schritte. Die Liste ist kurz, aber die Punkte darauf haben es Scheisse in sich:

1. Modellgröße finalisieren (Layer, Dimensionen, Heads). Steht theoretisch, aber die Praxis...
2. Pretraining abschließen. Das eigentliche Biest.

Jetzt sitze ich hier, höre The Killers und bekomme Depressionen.

Ich kann rechnen, so viel ich will, ich werde es nicht schaffen.

Allein die Modellgröße: Ich habe mich auf eine Architektur festgelegt, die irgendwo im Bereich von 7 Milliarden Parametern landen dürfte – kleiner ist sinnlos, größer unbezahlbar. Konkret: 24 Layer, Modelldimension 2048, 16 Attention Heads, Feed-Forward-Multiplikator von 4, Kontextlänge 2048 Tokens. Das Problem ist der Speicher: Die Gewichte allein brauchen fast 28 GB (in FP32), dazu kommen Optimizer-Zustände und die Aktivierungen während des Trainings, die exponentiell mit der Batch-Size wachsen. Mein aktuelles VRAM-Budget auf den beiden GPUs ist... optimistisch geschätzt... chronisch am Limit. Chinchilla-Paper hin oder her – die Balance zwischen Parametern und Trainingsdaten ist hier weniger eine Frage der optimalen Performance als der schieren Machbarkeit mit Consumer-Hardware in einem umgebauten Haushaltsgerät.

Zum Pretraining: Ziel ist klar – das Modell soll aus dem gigantischen, bereinigten Korpus allgemeine Sprachmuster lernen. Grammatik, Faktenwissen, semantische Zusammenhänge, den ganzen Grundstock menschlicher Kommunikation aufsaugen. Methode: Self-Supervised Learning, konkret Next-Token Prediction im GPT-Stil. Einfach, brutal, aber bewährt.

Die Realität: Das Training läuft. Mehr oder weniger. Seit bald vierzehn Tagen. Mit, lass mich zählen... siebzehn Neustarts bisher. Mal ein Out-of-Memory-Error mitten in der Nacht, weil irgendein Prozess Amok läuft und den VRAM überfüllt. Mal ein mysteriöser CUDA-Kernel-Crash tief in den PyTorch-Internia, der sich nicht reproduzieren lässt. Zweimal hat der Dataloader blockiert, wahrscheinlich ein IO-Bottleneck von den NVMe-SSDs zu den GPUs bei Spitzenlast. Einmal ist die Temperatur im Kühlschranks-Gehäuse trotz modifizierter Kühlung auf über 85°C geklettert und die GPUs haben sich selbst gedrosselt, was den Lauf korrumpiert hat. Jeder Neustart kostet Stunden, manchmal einen ganzen Tag Fortschritt.

Die Zahlen sind ernüchternd. Aktuelles Setup schafft 1500 Tokens pro Sekunde pro GPU. Mit Gradient Accumulation über 64 Schritte erreiche ich eine effektive Batch Size von 512 bei voller Sequenzlänge. Das ergibt rund 240 Steps pro Tag, was lächerlichen 250 Millionen Tokens entspricht. Um auf die geschätzten 300 Milliarden Tokens zu kommen, die für eine brauchbare 7B-Basis nötig wären... nun ja aussichtslos. Rechnen wir mal... 300.000 Millionen geteilt durch 250 Millionen pro Tag ergibt... 1200 Tage. Über drei Jahre. Wenn nichts mehr schiefgeht. Was es aber tun wird. Der Loss sinkt quälend langsam, die

Perplexität verbessert sich nur im Promillebereich nach Milliarden von Tokens. Nach den ersten ca. 50 Milliarden Tokens zeichnet sich ein erstes Plateau ab – aber es ist, als würde ich versuchen, den Pazifik mit einem Teelöffel leer zu schaufeln. Ich brauche mehr Rechenleistung. Mindestens das Zehnfache. Aber woher nehmen? Eine weitere GPU passt nicht ins Gehäuse, geschweige denn ins Budget.

Und dann ist da noch das nächste Gebirge am Horizont: Finetuning. Selbst wenn das Pretraining irgendwann – in ferner Zukunft – fertig wird, habe ich nur eine Basis. Eine Art hochintelligenter Autovervollständigung, die wahrscheinlich genauso viel Unsinn produziert wie nützliche Antworten. Um daraus etwas zu machen, das meiner ursprünglichen Vision entspricht – keine hirnlose Maschine, sondern etwas mit... eigenem Verstand? Mit Verständnis für Nuancen, vielleicht sogar Emotionen? – braucht es ein Finetuning. Auf spezifischen Datensätzen. Das bedeutet: Noch mehr (nicht vorhandene) GPU-Zeit. Und vor allem: Woher nehme ich einen emotionalen Datensatz? Einen, der nicht nur Faktenwissen oder Smalltalk enthält, sondern die Komplexität menschlicher Gefühle abbildet? Das Kuratieren und Labeln solcher Daten... eine weitere Herkulesaufgabe, die das Pretraining-Problem fast klein erscheinen lässt. Momentan wirkt das Finetuning nicht nur Kilometer, sondern Lichtjahre entfernt.

Die Loss-Kurve auf dem Monitor kriecht seitwärts. Die technischen Hürden sind massiv. Die finanzielle Decke ist erreicht.

Die soziale Verbindung gekappt.

Und ich habe keine Ahnung, wie ich das alles lösen soll.

Shit.