

## 7. Logbucheintrag 04/06/25

Es funktioniert nicht. Weder das Pretraining noch ansatzweise das Finetuning werden hier zu Hause jemals starten, geschweige denn abgeschlossen werden. Das ist keine Vermutung mehr, das ist das Ergebnis harter, unbestechlicher Kopfarbeit der letzten 48 Stunden. Ich habe die Logs der letzten zwei Wochen analysiert, die Fehlermeldungen katalogisiert, die Performance-Daten ausgewertet. Habe zig Rechnungen aufgestellt: Sechs verschiedene Konfigurationsszenarien durchgespielt, mit vier Varianten der Batch-Größe experimentiert, drei Sequenzlängen getestet. Das Ergebnis ist immer dasselbe: Scheitern. Die Engpässe sind systemisch: Mal limitiert das VRAM der beiden GPUs, mal überhitzt das System trotz optimierter Kühlung, mal hängt der Dataloader wegen I/O-Sättigung der NVMe-SSDs, mal gibt es unerklärliche Kernel-Crashes auf GPU-Ebene. Es ist, als würde man versuchen, einen Ozeanriesen mit einem Außenborder anzutreiben. Die Last ist zu groß.

Dazu kommt die Nebenbaustelle, die sich nicht länger ignorieren lässt: die Kosten. Der Kühltisch-Server zieht im aktuellen Trainingsmodus grob 800 Watt. Dauerhaft. Das sind fast 19 Kilowattstunden pro Tag. Bei den hiesigen Strompreisen summiert sich das auf geschätzte 250 Euro pro Monat – nur für den Strom. Und das für eine Trainingsgeschwindigkeit, die, wie berechnet, Jahre für das Pretraining benötigen würde. Die Zahlen lügen nicht: Skalierung hier zu Hause ist ökonomisch und technisch unsinnig. Punkt.

Also, Plan B. Die These ist klar: Ich habe hier genug Rechenleistung für Inferenz, für die Verwaltung, für kleinere Experimente, vielleicht sogar für ein rudimentäres Finetuning später. Aber nicht für das initiale, brute-force Pretraining auf Terabytes von Daten. Das muss ausgelagert werden. Cloud-Anbieter? Zu teuer, und wer weiß, wer da mitliest oder die Daten abgreift – inakzeptables Risiko. Freunde mit potenter Hardware? Unzuverlässig, zu viele Fragen. Bleibt nur eine Option, die sowohl die nötige Rechenleistung bietet als auch... eine gewisse Vertrautheit birgt: Der Uni-Cluster in Freiburg.

Der Plan ist riskant. Sehr riskant. Aber alternativlos. Es geht nicht darum, das System zu hacken – das wäre dumm und laut. Es geht darum, vorhandene, legitime Ressourcen unauffällig und unterhalb des Radars zu nutzen. Der Operationsplan steht:

1. **Anreise:** Unauffällig. Bahnticket, bar bezahlt. Kein Einloggen in öffentliche WLANs. Handy im Flugmodus. Keine digitalen Spuren hinterlassen.
2. **Zugang:** Alte Campus-Zugänge prüfen. Gibt es noch aktive Gast-Accounts? Legacy-Protokolle? Schwach konfigurierte Dienste an den Rändern des Netzwerks? Ziel ist ein leiser Einstieg über legitime Pfade, keine Brute-Force-Angriffe, keine Exploits. Operational Security ist alles.
3. **Daten:** Der bereinigte Korpus, bereits in handliche 512-MB-Shards zerlegt und mit Checksums versehen, muss auf einen unauffälligen Staging-Knoten im Uni-Netz transferiert werden.
4. **Transfer:** Muss nachts erfolgen, mit stark gedrosselten Raten – vielleicht 8 bis 12 MB/s über eine verschleierte VPN-Verbindung. Die Übertragung der [X] Terabyte wird dauern, schätzungsweise [Y] Tage. Geduld ist Teil der Tarnung.
5. **Training:** Das Cluster-Management-System (wahrscheinlich Slurm) nutzen. Nicht einen riesigen Job anfordern, sondern viele kleine, unabhängige Jobs auf möglichst

vielen (>100) verfügbaren GPUs verteilen, die jeweils nur einen Teil der Shards bearbeiten. Kurze Laufzeiten, häufige Checkpoints (alle 30 Minuten, klein, < 5 GB, verschleierte Dateinamen), Preemption (das vorzeitige Beenden von Jobs durch höher priorisierte Nutzer) fest einkalkulieren und eine robuste Retry-Strategie implementieren. Das Ganze muss aussehen wie Dutzende unzusammenhängende, kleine Experimente, nicht wie ein massives Pretraining.

6. **Monitoring:** Absolut diskret. Keine Web-Dashboards, keine auffälligen Performance-Monitor-Tools. Nur regelmäßiges Abrufen simpler Text-Logs mit den Kernmetriken. Automatische Kill-Switches implementieren, falls ein Job unerwartet hohe Last erzeugt oder zu lange läuft.

Es läuft auf eine Art digitale Guerilla-Aktion hinaus: Die Daten-Shards werden quasi als digitales Saatgut auf dem Uni-Cluster 'ausgesät' – einem System, auf dem ich eigentlich nichts verloren habe.

Die Cluster-Ökologie wird mein Gewächshaus: Ich nutze die Nachtfenster, wenn die Last geringer ist. Kleine, rotierende Log-Dateien und Checkpoints schützen vor Datenverlust bei Job-Abbrüchen. Die Daten-Shards mit ihren Prüfsummen sind der Schutz vor Korruption während des Transfers und Zugriffs. Die Retry-Strategie ist der Plan B gegen Preemption. Die erwartete Performance? Schwer zu sagen, hängt von der Auslastung ab. Aber selbst konservativ geschätzt, sollten 100+ GPUs den Durchsatz um mindestens Faktor 83 gegenüber meinem Heimserver steigern. Damit rückt das Erreichen des ersten Meilensteins – sagen wir, die ersten 50 Milliarden Tokens – in den Bereich von Wochen, nicht Jahren. Das ist machbar. Riskant, aber machbar.

Also gut. Entscheidung getroffen. Operation Freiburg wird initialisiert. Ich habe die wichtigsten Dinge gepackt: Der verschlüsselte Stick mit den Zugangs-Skripten und dem Plan. Die externen Festplatten mit den Daten-Shards, ebenfalls verschlüsselt. Mein altes Notizbuch. Ein paar Ersatzkabel. Kein persönlicher Kram, kein Ballast.

Soll ich jemensen Bescheid sagen? Nein. Absolute Funkstille. Diese Mission läuft unter dem Radar.

Sitze gleich im Nachtzug. Die Terminal-Prompts für morgen früh sind vorbereitet. Die Befehle stehen bereit.

Morgen schon setze ich den ersten Job.