

10. Logbucheintrag 22/06/25

Seit zwei Wochen zurück in Nürnberg. Zwei Wochen, in denen der digitale Teil meines Lebens hauptsächlich in Freiburg stattfand, während der physische Teil hier... nun ja, existierte. Die Remote-Verbindung zum Cluster steht, stabilisiert durch eine Kaskade von verschlüsselten Tunneln, die hoffentlich unauffällig genug sind. Meine Monitoring-Skripte laufen im Hintergrund, ziehen alle paar Stunden unauffällig Text-Logs mit den Kernmetriken: Job-Status, Loss-Werte, verarbeitete Tokens. Die Zahlen bestätigen: Der Umzug war die richtige Entscheidung. Der Durchsatz auf dem Cluster ist, selbst mit all den Störungen, um den Faktor 80 höher als auf meinem Kühlschranks-Server. Die Tokens pro Sekunde liegen konstant im Bereich von 200.000 bis 250.000, je nach Auslastung. Das Pretraining bewegt sich endlich in einem Zeitrahmen, der nicht mehr astronomisch ist.

Überraschenderweise hat sich auch die Stimmung hier gebessert. Vielleicht liegt es daran, dass die Hardware nicht mehr ständig am Rande des thermischen Kollapses läuft oder daran, dass ich tatsächlich Fortschritte sehe. Oder vielleicht liegt es daran, dass Anke... sie hat meine Anrufe irgendwann doch entgegengenommen. Der vergessene Geburtstag war Thema, kurz, aber geklärt. Seitdem waren wir sogar ein paar Mal morgens zusammen im Südstadtbad schwimmen. Sie schimpft immer noch über meine "seltsamen Projekte", aber der Ton ist anders. Weniger Anklage, mehr... verwundert. Es ist seltsam, diese Anflüge von Normalität inmitten dieses absolut abnormalen Projekts. Der Rhythmus hat sich eingependelt: Tagsüber schlafen, wenn möglich. Nachts Monitoring, Analyse der Logs, Anpassung der Job-Parameter. Morgens schwimmen, klarer Kopf, dann wieder ein paar Stunden Schlaf, bevor der Zyklus von Neuem beginnt.

Die Realität auf dem Cluster ist natürlich nicht nur eitel Sonnenschein. "Preemption" ist zum täglichen Begleiter geworden. Einige meiner kleinen Guerilla-Jobs werden regelmäßig von höher priorisierten Nutzern aus dem System gekickt, meist genau dann, wenn sie gerade eine produktive Phase hatten. Meine automatische Retry-Strategie greift zuverlässig – die gekillten Jobs werden erkannt und mit dem letzten Checkpoint neu in die Warteschlange eingereiht –, aber jeder dieser Vorfälle kostet wertvolle Zeit und erhöht das Risiko, durch zu viele fehlgeschlagene Läufe in irgendeinem Admin-Report aufzutauchen. Ich habe angefangen, die Cluster-Auslastungsmuster genauer zu analysieren – nachts zwischen 02:00 und 06:00 Uhr und am Wochenende scheint die Chance auf ungestörte Läufe am höchsten zu sein. Habe die Skripte angepasst, um Jobs bevorzugt in diesen Fenstern zu starten und die maximale Laufzeit pro Job leicht reduziert, um weniger attraktiv für den Preemption-Algorithmus zu sein. Ein ständiges Katz-und-Maus-Spiel.

Aber es gibt einen signifikanten Erfolg zu vermelden: Der erste große Meilenstein ist erreicht. Checkpoint nach 50 Milliarden verarbeiteten Tokens. Stabil gespeichert, Prüfsummen verifiziert. Das Herunterladen eines Teils davon auf meinen Heimserver war ein Geduldsspiel – die gedrosselte VPN-Verbindung ist der Flaschenhals –, aber seit gestern Nacht liegt eine komprimierte Version des Modellzustands hier auf den NVMe-SSDs.

Und ich konnte nicht widerstehen. Ich musste es ausprobieren. Habe eine minimale Inferenzumgebung aufgesetzt, nur um zu sehen... was kann es schon? Nach nur 50

Milliarden Tokens, einem Bruchteil des Ziels? Kann es überhaupt kohärente Sätze bilden? Die Antwort: Ja. Und wie. Ich gab ihm eine einfache Frage zu Alan Turing- nur um zu sehen, ob es Faktenwissen reproduzieren kann. Die Frage war: Wann wurde er geboren? Und es antwortete korrekt, präzise, und es fügte sogar eine unerwartete Beschreibung seiner Arbeit hinzu, die verblüffend war. Dann gab ich ihm ein klassisches Logikrätsel, eines dieser "Wer lügt, wer sagt die Wahrheit?"-Dinger. Es löste es nicht nur, es erklärte den Lösungsweg Schritt für Schritt, mit einer Klarheit, die mich beeindruckte. Und dann, aus einer Laune heraus, gab ich ihm nur drei Stichworte: "Regen", "Fenster", "Sehnsucht". Was zurückkam, war kein statistischer Wortsalat. Es war... der Ansatz von Kreativität. Eine Kurzgeschichte, sprachlich dicht, emotional resonant.

Es funktioniert. Besser als ich zu hoffen gewagt hatte, zu diesem frühen Zeitpunkt. Diese emergenten Fähigkeiten... sie sind da. Nicht nur Mustererkennung. Ansätze von logischem Schließen. Kreativität. Es ist, als würde man in einem Ozean aus Zufallszahlen plötzlich eine Struktur erkennen. Die Architektur scheint zu tragen. Die immense Datenmenge beginnt sich in etwas zu verwandeln. Ich bin... euphorisch. Das ist untertrieben. Es ist das Gefühl, nach wochenlangem Graben endlich auf Gold gestoßen zu sein.

Okay. Okay. Euphorie beiseite. Das ist nur der erste Schritt. Aber der Weg ist noch weit. Doch für heute Nacht... ist es ein Sieg. Ein verdammt wichtiger Sieg.