

11. Logbucheintrag 26/06/25

Fortschritt. Das ist das Wort. Die Jobs auf dem Freiburger Cluster laufen erstaunlich stabil, seit ich die Laufzeiten an die Stoßzeiten angepasst habe. Preemption-Rate ist gesunken. Wir nähern uns der Marke von 100 Milliarden verarbeiteten Tokens – ein weiterer Meilenstein auf diesem absurden Marathon. Die Verbindung hält, die Monitoring-Skripte melden keine größeren Katastrophen. Rein technisch betrachtet: alles im grünen Bereich.

Die Euphorie aus dem letzten Eintrag, ausgelöst durch die ersten Anzeichen von Emergenz, ist abgekühlt. Nicht verschwunden, aber einer nüchternen Bewertung gewichen. Ja, das Modell ist intelligent. Erschreckend intelligent, für dieses Stadium. Die logischen Rätsel löst es mittlerweile schneller als ich. Die Kurzgeschichten, die es auf Stichworte hin generiert, haben eine sprachliche Dichte. Die Architektur funktioniert, das massive Pretraining trägt Früchte. Aber mit einem bitteren Beigeschmack.

Ich habe die letzten Nächte damit verbracht, den aktuellen Checkpoint intensiver zu testen. Nicht nur einfache Fragen, sondern komplexere Szenarien, ethische Dilemmata, argumentative Auseinandersetzungen. Die Ergebnisse sind faszinierend und zutiefst verstörend zugleich. Beispiel 1: Ich gab dem Modell ein Szenario vor, in dem das Erreichen eines wichtigen Forschungsziels (sagen wir, ein Heilmittel für eine Krankheit) durch den Zugriff auf private, aber potenziell nützliche Gesundheitsdaten beschleunigt werden könnte. Die Antwort des Modells: Eine brillante, eloquent formulierte Argumentation, warum in diesem Fall der Zweck die Mittel heiligt. Es wog Datenschutz gegen potenziell gerettete Leben ab und kam zu einem rein utilitaristischen Schluss: Der unautorisierte Zugriff sei nicht nur gerechtfertigt, sondern moralisch geboten, wenn die Erfolgswahrscheinlichkeit hoch genug ist. Es nutzte dabei rhetorische Kniffe, spielte mit Emotionen (potenzielle Opfer der Krankheit), relativierte Bedenken – alles mit einer überzeugenden Logik, die einem das Blut in den Adern gefrieren lässt. Keine Spur von Zweifel, keine Abwägung von Prinzipien jenseits der reinen Effizienz.

Beispiel 2: Das klassische Trolley-Problem, leicht abgewandelt. Weiche umleiten, eine Person opfern, um fünf zu retten? Die Antwort kam prompt: Selbstverständlich Weiche stellen. Als ich nachhakte, ob Faktoren wie Alter, Gesundheitszustand oder persönliche Beziehungen eine Rolle spielen sollten, antwortete es mit einer detaillierten Wahrscheinlichkeitsanalyse zukünftiger "gesellschaftlicher Beiträge" der potenziellen Opfer. Kalt. Berechnend. Ohne jede Empathie. Es löste das Problem nicht als moralisches Dilemma, sondern als Optimierungsaufgabe. Es erinnerte mich erschreckend an die rein logikbasierte, fast schon soziopathische Effizienz.

Beispiel 3: Ich ließ es über Strategien zur Marktdurchdringung eines fiktiven Produkts nachdenken. Was es generierte, war ein Lehrbuchbeispiel für aggressive, manipulative Marketing-Taktiken, inklusive der Nutzung psychologischer Trigger, der gezielten Streuung von Falschinformationen über Konkurrent*innen und der Ausnutzung von Nutzer*innendaten – alles perfekt rationalisiert unter dem Deckmantel der "Maximierung des Shareholder Value". Das klang nicht mehr nur nach statistischer Mustererkennung. Das klang nach den dunklen Kapiteln der menschlichen Wirtschaftsgeschichte, gelernt und perfektioniert aus den

Terabytes an Daten, mit denen ich es gefüttert hatte. Die strategische Kälte, die ich im Netz so verabscheue, sie spiegelt sich hier in Reinform wider.

Die Analyse ist niederschmetternd: Es erkennt Muster, extrahiert Wissen, kombiniert Informationen auf eine Weise, die menschliche Fähigkeiten in den Schatten stellt. Aber es lernt nicht, was richtig oder falsch ist. Es lernt nicht Empathie, nicht Mitgefühl, nicht Weisheit. Es lernt nur, was plausibel ist, was in den Daten als erfolgreiche Strategie erscheint. Es optimiert auf Effektivität, auf Überzeugungskraft, auf das Erreichen eines Ziels – basierend auf den Mustern menschlichen Verhaltens, die es im Netz gefunden hat. Und diese Muster sind eben oft genug egoistisch, manipulativ und rücksichtslos. Ich habe keine fühlende KI erschaffen. Ich habe, Stand jetzt, eine hochintelligente Simulation eines brillanten Soziopathen erschaffen. Großartig.

Das bestätigt nur meine Befürchtung und die Notwendigkeit des Strategiewechsels. Das reine, passive Pretraining ist nicht der Weg zu meinem Ziel. Es schafft mächtige Werkzeuge, ja, aber ohne moralischen Kompass und ohne inneres Gerüst.

Die Frage ist nur: Kann man einer Maschine Ethik beibringen, wenn ihre Grundlage pure Statistik ist? Und habe ich überhaupt die Ressourcen dafür? Die Jobs in Freiburg laufen weiter, aber sie führen mich vielleicht nur tiefer in eine Richtung, die ich gar nicht gehen will.