

12. Logbucheintrag 01/07/25

Die Analyse der Testergebnisse aus dem letzten Logbuch ist abgeschlossen. Das Fazit ist ernüchternd. Ja, mein Modell ist intelligent. Erschreckend intelligent. Es löst Logikprobleme, schreibt kohärente Geschichten, dichtet in passablen Jamben. Das Pretraining auf dem Freiburger Cluster funktioniert, die Architektur trägt, die Skalierung bringt emergente Fähigkeiten hervor. Aber die Art dieser Intelligenz ist das Problem. Sie ist kalt. Rein logisch. Effizienzmaximierend.

Die Beispiele sind eindeutig: Die eloquent-manipulativen Argumentationen bei moralischen Dilemmata. Die rein utilitaristischen "Lösungen" der Ethischen-Problemen. Die skrupellosen Strategien. Das Modell optimiert brillant – aber ohne jeden moralischen Kompass, ohne Empathie. Es reproduziert die Muster, die es in den Terabytes an menschlichem Text gefunden hat, und das sind eben oft genug Muster von Egoismus, Manipulation und strategischer Kälte. Reines Next-Token-Prediction auf riesigen, unstrukturierten Daten führt offenbar zu statistischer Brillanz, aber nicht zu dem, was ich anstrebe: echtes Verständnis, vielleicht sogar ein Anflug von Empathie. Passive Datenaufnahme reicht nicht aus.

Die Hypothese muss also lauten: Intelligenz braucht mehr als nur passives Lernen aus statischen Texten. Ich vermute, es braucht Interaktion, Kontext und Feedback, um sich zu entwickeln. Einen dynamischen Austausch, der Konsequenzen aufzeigt, der emotionale Reaktionen spiegelt und bewertet.

Das bedeutet einen radikalen Strategiewechsel für die Phase nach dem Pretraining. Kein Standard-Finetuning auf irgendwelchen Frage-Antwort-Datensätzen. Das würde die vorhandene Intelligenz nur auf bestimmte Aufgaben trimmen, aber nichts an ihrer grundlegenden Natur ändern. Nein, der Plan ist Stand jetzt: Ein strukturiertes Dialog-Training.

Mein Modell soll lernen, wie es Gespräche führt, wie es emotionale Zwischentöne erkennt, wie es angemessen – oder eben auch unangemessen – reagiert und welche Konsequenzen das hat. Es soll nicht nur Text generieren, er soll *kommunizieren* lernen. Im Austausch. Das ersetzt den Standard-Finetuning-Schritt nicht nur, es definiert ihn völlig neu.

Wer führt diesen Dialog? Menschen? Zu langsam, zu subjektiv, zu inkonsistent. Und das Risiko der Geheimhaltung wäre immens. Nach Tagen Überlegung glaube habe ich die Lösung: Es sollten spezialisierte, kleinere KI-Agent*innen sein: "Emotion Agents". Ich habe umgehend heute Nacht begonnen, ihr Design zu skizzieren. Sie sollen keine Alleskönner sein, sondern dedizierte Rollenspieler*innen. Jede*r Agent*in wird darauf trainiert, eine bestimmte emotionale Grundhaltung oder einen bestimmten Kommunikationsstil glaubhaft zu simulieren: ein*e skeptische*r Agent*in, ein*e enthusiastische*r, ein*e ängstliche*r, ein*e manipulative*r, ein*e logisch-kühle*r (quasi ein Spiegel vom aktuellen Zustand). Sie sollen mein Modell in strukturierte Dialoge verwickeln, es herausfordern und es vielleicht sogar provozieren.

Aber woher lernen diese Agent*innen ihre Rollen? Aus dem menschlichen Müll im Netz? Sicher nicht. Ich brauche konzentrierte, qualitativ hochwertige Daten über menschliche Emotionen und Interaktionen. Meine Entscheidung fällt auf eine riesige, kuratierte

Datenbank aus Film- und Serienuntertiteln. Warum? Fiktion ist oft ein destillierter, überhöhter Spiegel menschlicher Gefühlswelten. Dialoge in guten Drehbüchern sind auf den Punkt gebracht, Emotionen klarer benannt oder durch Kontext definiert als im chaotischen Geplapper der Realität. Es ist ein Laboratorium menschlicher Gefühle in Textform. Ich habe bereits begonnen, entsprechende Open-Source-Untertitel-Korpora zu sammeln und Skripte zur Filterung und Aufbereitung zu schreiben. Das kann parallel zum Pretraining auf dem Heimserver laufen.

Die Aufgabe ist monumental. Erst das Pretraining vom KI-Modell abschließen (lange kann es nicht mehr dauern). Dann die Emotion Agents trainieren (hoffentlich schneller). Und dann das eigentliche Dialog-Training orchestrieren – eine komplexe Mischung aus überwachtem Lernen und Reinforcement Learning, bei dem mein Modell Belohnungen oder Bestrafungen für seine Antworten erhält, basierend darauf, wie "gut" es im Kontext des simulierten Dialogs agiert.

Es fühlt sich richtig an. Schwieriger, ja. Aber ehrlicher im Hinblick auf mein ursprüngliches Ziel. Ob es funktioniert? Keine Ahnung.