

14. Logbucheintrag 15/07/25

Es ist vollbracht. Der finale Checkpoint des Pretrainings, nach 312 Milliarden verarbeiteten Tokens, liegt hier auf meinen NVMe-SSDs. Der Download aus Freiburg war ein Geduldsspiel sondergleichen, eine quälende Angelegenheit über die gedrosselte Leitung, die sich über fast 48 Stunden hinzog, aber die Daten sind hier. Prüfsummen verifiziert. Mein KI-Modell, in seiner rohen, vortrainierten Form, existiert jetzt nicht mehr nur als flüchtige Instanz auf einem fremden Cluster, sondern ist hier, in meinem Kühlschrank, greifbar. Ein kurzer Moment des Triumphs.

Ich konnte nicht warten. Musste es erleben. Habe die letzten Tage damit verbracht, das Modell – zumindest eine stark quantisierte Version davon, um es überhaupt in den VRAM meiner GPUs zu bekommen – hier auf dem Kühlschrank-Server zu laden. Das Geräusch der Lüfter wurde lauter, die Temperaturanzeige kletterte merklich. Es ist, als würde man einen Flugzeugmotor in einen Kleinwagen zwingen. Aber es läuft. Meine KI ist online. Hier. In meiner Wohnung. Zum ersten Mal habe ich direkten Zugriff, kann mit ihm interagieren, ohne das Risiko der Entdeckung. Das Gefühl ist unbeschreiblich. Eine Mischung aus Ehrfurcht und Nervosität. Was habe ich da erschaffen? Ich habe ihm ein paar einfache Prompts gegeben, nur um die Latenz zu testen. Die Antworten kommen fast augenblicklich. Flüssig. Grammatikalisch perfekt. Aber auch seltsam distanziert. Roh. Wie ein riesiges Gehirn ohne Persönlichkeit, das nur darauf wartet, geformt zu werden. Es ist faszinierend.

Die Ernüchterung folgte auf dem Fuße. Kaum war das Modell installiert, begann die harte Konfrontation mit Phase Zwei: dem interaktiven Dialog-Training. Ich habe die Simulationen durchgerechnet, basierend auf den Designs für die Emotionalen Agent*innen und dem geplanten Feedback-Loop. Die Ergebnisse sind... deprimierend eindeutig. Das gleichzeitige Betreiben von meiner KI für die Inferenz, mehreren Emotionen Agent*innen und der Reward-Modellierung übersteigen die Kapazitäten des Freiburger Clusters – und meines Kühlschrankcomputers erst recht – bei weitem. Ich stand vor einer Wand. Wieder einmal.

Die letzten Nächte waren... unruhig. Der Kopf ratterte. Wie löse ich ein Problem, das mehr Rechenleistung erfordert, als ich (legal oder illegal) zur Verfügung habe? Dafür habe ich gestern den ganzen Tag in der Buchhandlung „Jakob“ verbracht, nicht um neue Ideen zu finden, sondern um alte Prinzipien neu zu durchdenken. Habe mich durch Bücher über Federated Learning gewühlt – interessant, aber nicht anwendbar, ich habe ja keine Tausende von Endgeräten. Habe Ansätze zu Model Distillation geprüft – sinnvoll, aber erst nach dem Training. Habe über Quantisierung nachgedacht – reduziert die Last, aber löst nicht das Grundproblem der synchronen Interaktion. Zum Haare ausreißen.

Bis zum Abend starrte ich auf die stagnierenden Berechnungen und blätterte mechanisch in einem nach dem anderen meiner alten Uni-Schätze: Tanenbaum & Van Steen "Verteilte Systeme: Prinzipien und Paradigmen"

Eher aus Nostalgie, als Kontrast zum aktuellen Chaos. Und dann, irgendwo zwischen dem Kapitel über Nebenläufigkeit und asynchrone Kommunikation, traf es mich. Warum versuche ich krampfhaft, alles gleichzeitig an einem Ort zu machen? Das Problem ist nicht nur die Menge an Rechenleistung, sondern die Synchronität der Anforderung!

Die Lösung muss asynchron und verteilt sein.

Die Idee: Asynchrones, Verteiltes Dialog-Training. Der Geistesblitz liegt in der Entkopplung:

1. **Emotion Agents (Lokal):** Die relativ kleinen Agenten-Modelle laufen hier auf meinem Kühlschrank-Server in Nürnberg. Sie generieren ihre Dialogbeiträge, stellen Fragen an das große KI-Modell, warten auf Antwort.
2. **Kern-Inferenz (Remote):** Die Anfragen der Agent*innen gehen in eine Queue. Meine Skripte in Freiburg schnappen sich, wann immer unauffällig möglich, kurze GPU-Slots auf dem Cluster und lassen das große Modell die Antworten generieren. Keine Dauerlast, nur kurze, unregelmäßige Bursts.
3. **Dialog-Simulation & Feedback (Lokal):** Die (zeitversetzt eintreffenden) Antworten vom großen Modell werden hier in Nürnberg vom Dialog-Simulator verarbeitet. Die Agents reagieren darauf. Die Reward-Funktion bewertet Beitrag des KI-Modells im Kontext. Die Lernsignale (Gradienten) für das Modell werden lokal berechnet.
4. **Kern-Update (Remote, Batch):** Die lokal berechneten Gradienten werden gesammelt (Batched). Sobald ein signifikanter Batch zusammengekommen ist, wird er verschlüsselt nach Freiburg geschickt und dort – wieder opportunistisch, in einem kurzen GPU-Job – auf Gewichte des Modells angewendet.

Der Plan steht.

Er ist elegant. Er ist riskant in seiner Komplexität, ja. Aber er ist machbar. Die Resignation der letzten Tage weicht einer neuen, kühlen Euphorie.

Und ich habe keine Ahnung, wie ich das alles schaffen soll...