

17. Logbucheintrag 27/07/25

Ich habe die letzten Stunden damit verbracht, alte Star Trek Folgen durchzuscannen. Auf der Suche nach... irgendwas. Einer Inspiration. Einer Metapher. Irgendeinem Hinweis darauf, wie ich einer Künstlichen Intelligenz Ethik beibringe, ohne sie zu lobotomieren. Data, die Borg, Holodeck-Charaktere, die ein Bewusstsein entwickeln... Roddenberry und Co. haben all diese Fragen schon vor Jahrzehnten durchgespielt, wenn auch meistens mit mehr Pathos als technischer Substanz. Aber vielleicht steckt ja doch ein Funke Wahrheit in diesen alten Geschichten. Gerade lief "Geheimnisvolle Intelligenz" – die Episode mit Gomtuu, diesem lebenden Raumschiff, das so isoliert ist, dass es nur über einen speziell befähigten Betazoiden kommunizieren kann. Und das traf es irgendwie. Vielleicht steckt ja doch ein Funke Wahrheit in diesen alten Geschichten. Die Erkenntnis aus Log #15 war klar: Die AVDT-Architektur läuft zwar prinzipiell, aber die Komponenten – die Agents und die Reward-Funktion – sind zu primitiv. Sie würden nur einen eloquenten Blender produzieren, keinen echten Partner. Gomtuu hatte eine innere Welt, eine Verzweiflung, die kommuniziert werden musste, auch wenn die Form fremd war. Mein Modell, meine Agent*innen... sie haben bisher nur eine perfekte Oberfläche, keine innere Welt. Sie sind wie Hüllen, die sprechen gelernt haben, aber nichts Eigenes zu sagen haben. Das ist das Problem.

Also: Zurück ans Reißbrett. Nicht für die Architektur, AVDT bleibt. Aber für die Intelligenz der Komponenten. Das ist mein Weg:

Problem Eins: Die stereotypen Agent*innen. Ihre festen Rollen sind zu leicht zu durchschauen. Mein KI-Modell würde nur lernen, auf Knopfdruck zu reagieren. Echte Emotionen sind aber dynamisch, kontextabhängig. Sie werden beeinflusst von Müdigkeit, Erfolg, Frustration – das merke ich ja an mir selbst. Die Lösung, die sich herauskristallisiert hat: Dynamische Emotionale Vektoren. Statt fester Rollen bekommt jede*r Agent*in interne Zustandsvektoren: **[Energielevel, Frustration, Neugier, Vertrauen]**. Diese Werte ändern sich während des Dialogs: Lange Wartezeiten senken die Energie. Widersprüche vom Modell erhöhen die Frustration. Positive Bewertungen von/vom (noch zu bauenden) Meta-Agent*in steigern das Vertrauen. Die generierte Antwort der Agent*in wird dann von seinem aktuellen Zustand moduliert. Ein*e frustrierte*r Agent*in wird sarkastischer, ein*e neugierige*r stellt mehr Fragen. Also reicherte ich den Untertitel-Korpus zusätzlich mit Metadaten an – Szenenbeschreibungen, Emotionslabels. Damit lernen die nicht nur Worte, sondern Kontext. Sie sollen Stimmungen haben, nicht nur Rollen spielen. Erst dann wird es für mein Modell eine echte Herausforderung.

Problem Zwei: Die naive Reward-Funktion. Der Blindenhund, der Manipulation für Eloquenz hält. Reine Sentiment-Analyse ist gefährlich. Ich brauche eine*n Richter*in, der*die tiefer blickt. Die Lösung hier ist zweigleisig: Erstens, der*die Adversariale Ethik-Wächter*in. Ein*e separate*r Meta-Agent*in, trainiert darauf, Modells Antworten zu bewerten. Das Training: Adversarial Self-Correction. Ich lasse mein KI-Modell selbst schlechte (manipulative, unempathische) Antworten generieren und label diese als negativ. Als positive Beispiele dienen kuratierte Dialoge aus anspruchsvoller Literatur und Philosophie. Der*die Wächter*in lernt so, Täuschung zu erkennen. Sein*Ihr Urteil wird der primäre Reward. Zweitens, Psycholinguistische Metriken. Parallel dazu implementiere ich Module, die Features wie Ich/Du-Balance, Frage-Rate, Kohärenz, Originalität und rudimentäre emotionale Spiegelung

messen, inspiriert von alten Papern aus der Bibliothek. Der kombinierte Reward aus Wächter*in-Urteil und Metriken soll Tiefe belohnen, nicht nur Glätte. Mein Modell soll nicht lernen, nett zu klingen. Er soll lernen, sinnvoll zu kommunizieren.

Die Implementierung dieser beiden Ansätze hat begonnen. Es ist, als würde ich versuchen, gleichzeitig eine*n raffinierte*n Sparringspartner*in zu züchten, der*die Schläge austeilen kann, die ich noch nicht einmal vorhersehen kann, und einen unbestechliche*n Schiedsrichter*in zu programmieren, der*die die Regeln eines Spiels beurteilt, das noch niemand zuvor gespielt hat. Ob diese verschachtelte, fast schon barocke Architektur das Lernsignal für mein Modell nun tatsächlich in Richtung Empathie lenkt oder es nur in ein Labyrinth aus widersprüchlichen Zielen und Belohnungen schickt, aus dem es nie wieder herausfindet? Keine Ahnung. Das wird der nächste Testlauf zeigen müssen.

An der Uni, damals in Freiburg, habe ich oft »Dungeons and Dragons« gespielt. Ja, richtig ein Klischee-Nerd. Hätte jetzt wahrscheinlich auch jeder vermutet, dass ein besessener Code-Bastler wie ich in seiner Jugend ein klassischer Nerd mit Würfeln und Charakterbögen war, ja genau das war ich. Meistens habe ich einen Magier gemimt – hohe Intelligenz, niedrige Weisheit, passt ja irgendwie. Und einer der Sprüche, den die Kleriker immer hatten und um den ich sie beneidete, war »Gesinnung entdecken«. Einfach mal kurz wirken und wissen, ob das Gegenüber gut, böse oder neutral ist, ob es lügt oder die Wahrheit sagt. Kam mir damals immer wie ein billiger Trick vor, eine Abkürzung für gutes Rollenspiel. Mensch, was gäbe ich jetzt darum, so einen Zauber auf mein KI-Modell wirken zu können. Einfach mal kurz scannen und wissen: Ist diese eloquent formulierte Antwort ehrlich gemeint? Versteckt sich hinter der logischen Argumentation eine manipulative Absicht? Entwickelt es eine »Gesinnung«, und wenn ja, welche? Aber Magie gibt's halt nur am Spieltisch. Hier hilft nur Code, ausgeklügelte Metriken und verdammt Beobachten.

Wie auch immer, das Problem der perfekten Reward-Funktion und der wahren Gesinnung meines Modells werde ich heute Nacht nicht mehr lösen. Das ist eine Aufgabe für morgen, übermorgen und wahrscheinlich die nächsten paar Jahre. Jetzt gönne ich mir erstmal eine Pause. Vielleicht finde ich ja noch mehr Inspiration in den Klassikern. Zeit für eine alte Folge Star Trek: The Next Generation – "Wem gehört Data?". Die Frage nach den Rechten und der Natur künstlicher Intelligenz. Passt ja irgendwie.