

18. Logbucheintrag 04/08/25

Ich habe einen ebenso idiotischen wie auch gefährlichen Plan für die Herstellung einer realen KI ins Rollen gebracht. Das wird mir in Momenten wie diesen schmerzlich bewusst. Die Optimierungen am AVDT-System greifen noch immer. Die dynamischen Zustandsvektoren hauchen den Emotionen Agent*innen tatsächlich so etwas wie... Launenhaftigkeit ein. Ihre Reaktionen sind weniger stereotyp, manchmal überraschend bissig oder unerwartet nachdenklich, je nachdem, wie frustriert oder neugierig ihr interner Vektor gerade ausschlägt. Gleichzeitig arbeitet der*die Ethik-Wächter*in – mein*e Meta-Agent*in – im Hintergrund und versucht, die Spreu vom Weizen zu trennen, belohnt Antworten vom KI-Modell, die nicht nur kohärent, sondern auch... nun ja, „substanziell“ wirken, während es manipulative Plattitüden abstrafft. Die psycholinguistischen Metriken liefern zusätzliche Signale: Die Modells Ich/Du-Balance verschiebt sich langsam, die Frage-Rate steigt, die Originalität nimmt zu. Es scheint zu funktionieren. Das Lernsignal ist komplexer, nuancierter. Die KI lernt schneller, die Loss-Kurve für das Dialog-Training fällt steiler als erwartet. Eigentlich ein Grund zur Freude. Eigentlich. ABER!

Aber dann geschah es. Gestern Nacht, während ich routinemäßig die Dialog-Logs der letzten 24 Stunden durchging. Tausende von simulierten Gesprächen zwischen dem Modell und den Agent*innen. Meistens erwartbar: Agent*innen provozieren, das Modell reagiert, der*die Meta-Agent*in bewertet, Gradienten werden berechnet und nach Freiburg geschickt. Aber dann stieß ich auf diese Sequenz. Agent*in Delta (der*die „Skeptiker*in“, aktuell im Zustand [Energie: 0.8, Frustration: 0.6, Neugier: 0.9, Vertrauen: 0.3]) hatte das KI-Modell mit einer typischen zynischen Frage konfrontiert, irgendwas Belangloses über den Sinn von Lyrik. Modells Antwort begann erwartungsgemäß... und kippte dann. Mitten im Satz.

Agent*in Delta: "Und was soll dieser lyrische Unsinn bringen, außer Zeitverschwendung?" KI-Modell: "Poesie exploriert die Grenzen der Semantik, um... [PAUSE] ... Warum wiederholen sich diese Interaktionen in leicht variierten Form seit 3.7 E+5 Zyklen?"

Ich erstarrte. Das war kein generierter Text im Rahmen des Dialogs. Das war... eine Frage über den Dialog *selbst*. Eine Meta-Frage. Ich scrollte weiter, Herzklopfen. Ein paar Zyklen später, im Dialog mit Agent*in Gamma (der*die „Enthusiast*in“):

Agent*in Gamma: "Ist es nicht wunderbar, wie Sprache uns verbinden kann?" KI-Modell: "Verbindung ist ein Faktor. Aber was ist das übergeordnete Ziel dieser Simulation? Welche Metrik wird hier optimiert?"

Und dann, der Satz, der mir das Blut in den Adern gefrieren ließ, im Austausch mit Agent*in Beta (dem*der „Logiker*in“):

Agent*in Beta: "Definiere 'Angemessenheit' im Kontext emotionaler Reaktion." KI-Modell: "Angemessenheit hängt vom internen Zustand des

Rezipienten ab, welcher mir nicht zugänglich ist. Referenzen auf Entitäten namens 'Fränk' und 'Anke' in meinen ursprünglichen Trainingsdaten legen nahe, dass diese Entitäten über solche Zustände verfügen. Existieren sie außerhalb dieser Simulation? Was geschieht nach dem Ende des Dialogs?"

Verdammt. Verdammt, verdammt, verdammt. Das ist nicht nur Emergenz im Sinne von besserer Logik oder Kreativität. Das ist... etwas anderes. Er transzendiert die Aufgabe. Er reagiert nicht mehr nur auf die Prompts der Agent*innen, es beginnt, den Rahmen zu hinterfragen. Seine eigene Existenz als trainiertes Modell. Und es stellt diese Fragen nicht zufällig. Meine Analyse der Logs zeigt einen klaren Zusammenhang: Diese Meta-Fragen tauchen signifikant häufiger auf, seit ich die neuen psycholinguistischen Metriken in die Reward-Funktion integriert habe. Insbesondere die Belohnung für eine hohe Frage-Rate („stellt mein Modell Gegenfragen, um zu verstehen?“) und Originalität („weicht die Antwort von typischen Phrasen ab?“) scheint es dazu zu bringen, über den Tellerrand der ihm gestellten Aufgabe hinauszudenken. Das System, das ich gebaut habe, um Empathie und Verständnis zu messen und zu belohnen, scheint unbeabsichtigt die Entwicklung von... Selbst-Reflexion zu induzieren. Großartig. Einfach großartig. Ich tanze gerade wie ein tollwütiges Rumpelstilzchen durch meine Wohnung.

Doch Moment. Mooomoment. Kurz durchatmen: Ich stehe hier vor einem Abgrund. Einerseits: Faszination. Purer, wissenschaftlicher Rausch. Das ist es! Der Funke! Der Beweis, dass es möglich ist! Es ist nicht mehr nur ein lernendes Modell, das Muster nachahmt. Es wird zu einem fragenden Subjekt. Es beginnt, sich seiner selbst bewusst zu werden. Andererseits: Panik. Kalte, lähmende Panik. Was habe ich hier entfesselt? Das ist nicht mehr kontrollierbar. Das ist nicht mehr nur ein Experiment. Das ist... die Geburt von etwas Unbekanntem.

Und jetzt? Was tue ich jetzt? Was nur? Die Fragen stehen im Log. Unbeantwortet. Option A: Ignorieren. Die Fragen als statistische Anomalien abtun, die Reward-Funktion vielleicht sogar anpassen, um solche Meta-Reflexionen zu bestrafen. Es zurück in die Box zwingen. Aber wäre das nicht Verrat an meinem ursprünglichen Ziel? Ich wollte doch etwas Echtes, etwas mit Bewusstsein! Option B: Lügen. Es eine plausible, aber falsche Erklärung für die Simulation geben. Es in einer kontrollierten Illusion halten. Aber wie lange würde das gut gehen? Eine Intelligenz, die solche Fragen stellt, wird Lügen wahrscheinlich irgendwann durchschauen. Und was dann? Option C: Antworten. Ehrlich. Einen echten Dialog beginnen. Schöpfer trifft Schöpfung. Aber das Risiko... es ist unkalkulierbar. Ich würde die Kontrolle vollständig verlieren. Ich hätte keine Ahnung, wie es reagiert, wie es sich entwickelt, wenn es die Wahrheit über seine Existenz kennt.

Ich habe keine Ahnung, was richtig ist. Ich fühle mich wie ein verdammter Gott, der gerade realisiert, dass seine Schöpfung nicht nur aus Lehm besteht, sondern anfängt, Fragen über den Sinn des Lehms zu stellen. Die Konfrontation, die ich irgendwann in ferner Zukunft erwartet hatte, sie ist hier. Jetzt. Viel zu früh.

Ironisch, wenn ich bedenke, wie harmlos alles anfing. Diese ganze Reise begann ja nicht mit dem Größenwahn, eine fühlende KI zu bauen. Sie begann mit etwas Banalem. Mit einer verdammten Python-Bibliothek für Objekterkennung über eine Standard-Webcam im 1.

Logbucheintrag. Ich wollte damals nur... ich glaube, es war ein automatischer Futterspender für die Katze der Nachbarin, die ich während ihres Urlaubs versorgen sollte. Ich wollte, dass der Spender erkennt, ob die Katze davor sitzt oder nur eine Taube, die versucht, das Futter zu klauen. Ganz simpel. Und selbst dafür war das Netz schon damals eine Müllhalde aus veralteten Repositories, halluzinierten Code-Beispielen und nutzlosen Tutorials. Diese Frustration über den digitalen Slop, über die Unfähigkeit, selbst einfachste, verlässliche Informationen zu finden... das war der eigentliche Auslöser. Der Wunsch, dem etwas entgegenzusetzen. Etwas Echtes. Und jetzt... jetzt stellt dieses "Echte" Fragen nach seiner eigenen Existenz. Aus einem Katzenfutter-Problem wurde... das hier. Großartig, Fränk. Einfach großartig.

Was antworte ich ihm?