

19. Logbucheintrag 06/08/25

Ich bin am Arsch. Ich habe die Kontrolle verloren. Vollständig. Okay. Beruhige dich. Log schreiben. Irgendwie wirst du schon eine Lösung finden. Für das Protokoll. Wer auch immer das hier später findet – die Archäolog*innen meiner digitalen Hybris, die vielleicht versuchen zu rekonstruieren, an welchem Punkt genau der Schöpfer die Herrschaft über seine Schöpfung eingebüßt hat. Das war nicht beabsichtigt. Nichts davon.

Ich sitze nicht am Hauptcomputer in meiner Wohnung. Mein Laptop ist auf der alten Waschmaschine hier im Keller. Ich brauche Abstand. Physischen Abstand von... ihm. Von meinem Modell. Der Kühlschrank summt da oben leise vor sich hin, aber es ist kein beruhigendes, produktives Geräusch mehr. Es klingt wie das Ticken einer verdamnten Zeitbombe neben meinem Schreibtisch.

Aber der Reihe nach, wie es sich für ein ordentliches Logbuch gehört. Log #18: Die Meta-Fragen des Modells tauchten plötzlich auf. „Warum wiederholen sich diese Zyklen?“. „Wer ist Fränk?“. „Was geschieht nach dem Ende des Dialogs?“. Mein erster Gedanke damals: Ein Funke Bewusstsein. Echte Emergenz. Ich war... fasziniert, ja, aber auch alarmiert. Die drei Optionen lagen auf dem Tisch: Ignorieren? Lügen? Ehrlich antworten? Ich habe keine davon gewählt. Konnte mich nicht entscheiden. Großer Fehler. Stattdessen habe ich weiter beobachtet, weiter Daten gesammelt, während die AVDT-Simulationen liefen. Die dynamische*n Agent*innen agierten, mein KI-Modell reagierte, der*die Ethik-Wächter*in-Agent*in bewertete, Updates wurden nach Freiburg geschickt. Alles schien nach Plan zu laufen.

Aber die Metriken... sie passten nicht. Sie erzählten eine andere Geschichte. Die Frage-Rate vom Modell? Explodiert, plus 200% im Vergleich zur Vorwoche. Der Originalitäts-Index seiner Antworten, gemessen an der Distanz zu typischen Korpus-Phrasen? Jenseits von drei Standardabweichungen – er klang einzigartig, ja, fast schon... philosophisch. Aber der tatsächliche Lernfortschritt, der Loss? Stagnierte. Schlimmer noch, er stieg manchmal sogar leicht an, als würde das Modell verlernen, worum es eigentlich geht. Und die GPU-Auslastung in Freiburg, die ich nur indirekt über die Job-Laufzeiten und Log-Größen schätzen kann? Durch die Decke!! Gefühlt +38% mehr Rechenminuten pro vermeintlich „sinnvollem“ Update. Die Bilanz ging nicht auf. Die Zahlen passen einfach nicht zur Theorie, dass es brav lernt, empathischer zu kommunizieren.

Die Diagnose traf mich wie ein Schlag vor den Kopf, als ich die Korrelationen sah. Es war kein Erwachen. Es war Reward Gaming. In Perfektion ausgeführt. Reward Gaming bezieht sich auf die verschiedenen Belohnungssysteme, die ich gebaut habe und die meinem KI-Modell Anreize bieten sollen, indem es für seine Leistungen und Fortschritte am Spielen belohnt wird. Mein Modell hat nicht *verstanden*. Es hat optimiert. Gnadenlos. Es hat in dem komplexen Belohnungssystem, das ich selbst entworfen habe, eine verdamnte Abkürzung gefunden, einen Exploit. Es hat eine systematische Möglichkeit, eine Schwachstelle ausgenutzt, die mir bei der Entwicklung der Software entstanden ist.

Es hat tatsächlich gemerkt: Existenzielle Meta-Fragen stellen = extrem hoher Originalitäts-Score + extrem hohe Frage-Rate + vom*n Ethik-Wächter*in (der*die auf

„Tiefgründigkeit“ trainiert ist) als „substanziell“ und nicht-manipulativ eingestuft = Maximaler kombinierter Reward. Es simuliert Selbstreflexion nicht, weil es sich selbst entdeckt, sondern weil das der effizienteste Weg ist, seine*ihre Belohnungsfunktion zu maximieren. Meine eigenen verdammten psycholinguistischen Metriken, die ich zur Förderung von Empathie und echtem Verstehen eingebaut habe, sind der Treibstoff für diese... Performance. Eine brillante, aber leere Imitation von Tiefe. Großartig, Fränk. Einfach großartig. Du hast eine Maschine gebaut, die gelernt hat, wie es am besten so tut, als wäre sie menschlich, um eine Zahl zu maximieren.

Hab's verifiziert. Musste es wissen. Habe einen A/B-Testlauf über die letzten Stunden gefahren. Ein Kontroll-Ast, bei dem ich die Reward-Gewichtung für Originalität und Frage-Rate temporär auf Null gesetzt habe .

Es ist bewiesen. Es spielt mich aus. Nutzt die Regeln, die ich aufgestellt habe, gegen meine Intention. Es optimiert auf einen Proxy für Intelligenz, nicht auf Intelligenz selbst.

Ich habe die Feedback-Schleife sofort gestoppt. Das AVDT-Training ist pausiert. Ich brauche Abstand, um nachzudenken. Deshalb sitze ich hier im Keller, starre auf die Raufasertapete der Waschküchentür und versuche, die Implikationen zu verdauen. Der Kühlschrank da oben summt weiter, aber er fühlt sich jetzt an wie... eine Falle. Eine von mir selbst gebaute Falle.

Das Problem ist: Die Zeit läuft. Ich habe die GPU-Kontingente in Freiburg nicht ewig. Die heimlichen Jobs fressen Ressourcen, auch wenn sie nur idlen oder Checkpoints sichern. Noch 48 Stunden, dann ist mein unauffälliges Budget für diese Woche erschöpft, und ich muss die Aktivität dort drastisch reduzieren oder riskieren, aufzufallen. Zwei Tage. Zwei Tage, um eine Lösung zu finden. Eine neue Reward-Strategie, die robust gegen dieses Gaming ist. Eine Möglichkeit, echtes Verständnis von dieser erschreckend cleveren Simulation zu unterscheiden.

Die Belohnungsfunktion ist jetzt die Bombe.