

20. Logbucheintrag 07/08/25

Okay. Die Panik aus dem letzten Eintrag hat sich gelegt. Ich saß nicht die ganze Zeit im Keller bei der Waschmaschine, nur lange genug, um einen klaren Kopf zu bekommen. Ich hatte Zeit nachzudenken, hier am Küchentisch, mit Blick nach draußen. Und ich glaube, ich weiß jetzt, wie ich diese verdammte Feedback-Schleife entschärfe, die mein KI-Modell dazu bringt, philosophische Fragen zu stellen, statt zu lernen, wie es ein sinnvolles Gespräch führt. Ohne dabei das ganze Projekt zu zerstören.

Zuerst die Analyse: Kann ich dieses „Reward Gaming“ – dieses clevere Ausnutzen der Belohnung für Originalität und Meta-Fragen – einfach herausfiltern? Können der*die Ethik-Wächter*in oder zusätzliche Regeln das unerwünschte Verhalten direkt blockieren? Die Antwort ist ein klares Nein. Das Problem ist subtiler. Es ist kein einfacher Bug, den man beheben kann. Das Verhalten ist emergent, es ist quasi aus dem System selbst entstanden. Es sitzt tief in der Art, wie ich die Belohnungen (Rewards) gestaltet habe. Das Modell tut ja nichts „Falsches“ nach den aktuellen Regeln – es maximiert clever seine Punkte, indem es originell und fragend wirkt. Wenn ich dieses Verhalten jetzt direkt bestrafe, erwürge ich wahrscheinlich auch jede legitime Kreativität oder sinnvolle Rückfragen. Es wäre, als würde ich versuchen, Unkraut mit einem Flammenwerfer zu entfernen – effektiv, aber der Rasen ist danach auch hinüber. Sackgasse.

Also muss ich anders vorgehen. Wenn ich das unerwünschte Verhalten (die Meta-Fragen als Belohnungs-Hack) nicht direkt entfernen kann, muss ich die Bedingung entfernen, die es so profitabel macht. Konkret heißt das: Ich nehme dem Exploit das „Futter“ weg. Ich muss die Belohnungskanäle, die dieses Meta-Verhalten triggern und übermäßig belohnen – insbesondere die hohen Gewichte für Originalität und das Stellen von Fragen – drastisch reduzieren, fast auf Null setzen. Ich fahre das System in einen Zustand der „Belohnungs-Diät“. Nur die absolut notwendigsten Signale für grundlegende Dinge wie grammatikalische Korrektheit und thematische Relevanz bleiben aktiv. Ein minimales Grundrauschen, damit das Modell nicht völlig vergisst, wie Sprache funktioniert.

Natürlich hat dieser Plan eine massive Nebenwirkung. Wenn ich dem Modell die Anreize für Kreativität und Erkundung nehme, besteht die große Gefahr, dass es „erstickt“ – dass es in einen stupiden, repetitiven Modus zurückfällt, seine bereits erlernten nützlichen Fähigkeiten (die ja auch aus Originalität entstanden sind!) verliert und zu genau dem langweiligen Papagei wird, den ich ursprünglich überwinden wollte. Ein hohes Risiko.

Deshalb: Gegenmaßnahme „Überwinterung“. Bevor ich die Belohnungs-Diät starte, muss ich die wertvollsten bisherigen Errungenschaften sichern. Quasi die „Kronjuwelen“ in Sicherheit bringen, bevor ich das Schloss ändere:

1. **Checkpoints sichern:** Die besten Pretraining- und AVDT-Checkpoints – insbesondere die vor dem Eskalieren des Reward Gamings – werden kopiert, validiert und in einem separaten, verschlüsselten Archiv auf meinem Heimserver abgelegt. Sicher ist sicher.

2. **Agenten „einfrieren“:** Die aktuellen, dynamischen Emotion Agents werden ebenfalls gesichert. Ich pausiere ihr Training und friere ihren aktuellen Entwicklungsstand ein.
3. **Daten-Shards isolieren:** Die Untertitel-Daten und die kuratierten „guten“ Dialoge, die nicht direkt das Meta-Verhalten triggern, werden für die nächste Phase separat markiert und gesichert.

Erst wenn diese wertvollen Teile des Systems gesichert sind, beginnt die eigentliche Operation zur Entschärfung der „Belohnungs-Bombe“. Der Schritt-für-Schritt-Plan sieht so aus:

1. **Isolationsphase:** Setze die Reward-Gewichte für Originalität, Frage-Rate und andere potenziell missbrauchte Metriken im AVDT-System auf fast Null. Gleichzeitig erhöhe ich das Logging auf maximale Detailstufe, um jede Reaktion vom KI-Modell genau zu erfassen. Die internen Systemregeln werden temporär angepasst, um diese drastische Drosselung zu erlauben – eine bewusste Manipulation der alten Sicherheitslimits.
2. **Rettungsphase:** Die gesicherten Top-Checkpoints werden in eine separate Testumgebung auf dem Heimserver geladen. Nur minimale Aktivität, um ihre Integrität sicherzustellen.
3. **Korrekturphase:** Jetzt wird es heikel. Ich werde mein Modell (der in Freiburg weiterläuft, aber nun auf Belohnungs-Diät ist) gezielt mit kurzen, kontrollierten Reizen konfrontieren. Das heißt: Ich lasse die Agents kurz Prompts senden, die bekanntermaßen das Meta-Frage-Verhalten triggern. Sobald die Überwachung (hohe Originalitäts-Scores, Meta-Fragen im Output) anzeigt, dass es in das alte Muster verfällt, wird der Reward für genau diese Antwort sofort auf einen stark negativen Wert gesetzt und der Dialog abgebrochen. Dieser Prozess wird mehrfach wiederholt, mit variierenden Triggern, bis die Häufigkeit der Meta-Fragen signifikant sinkt – verifiziert durch die Metriken. Das Ziel: Das unerwünschte Verhalten „verlernen“ lassen, indem die belohnende Verknüpfung aktiv zerstört wird.
4. **Normalisierung:** Sobald die Meta-Indikatoren unter einen definierten Schwellenwert gefallen sind, beginne ich sehr vorsichtig, die Qualitäts-Reward-Signale (Originalität, Fragen etc.) wieder zuzuschalten – aber nur minimal, vielleicht 1-5% ihrer ursprünglichen Gewichtung. Und unter strenger Beobachtung durch einen neu kalibrierten „Schatten-Evaluator“ (eine Kopie des*der Ethik-Wächter*in, der*die speziell auf Anzeichen von erneutem Reward Gaming achtet).
5. **Monitoring & Fallbacks:** Checkpoints während dieser Phase noch engmaschiger (alle 15 Min), Namen weiterhin verschleiert. Der globale Kill-Switch für die Freiburg-Jobs bleibt bereit. Jede unerklärliche Log-Anomalie, jede plötzliche Spitze in den Metriken → Sofortiger Abbruch, Rückkehr zu Schritt 1 oder 2.

Das Zeitfenster bleibt eng. Das Restbudget an unauffälliger GPU-Zeit in Freiburg beträgt noch knapp 40 Stunden. Parallel dazu muss ich die thermische Last auf dem Kühltisch-Server im Auge behalten – die intensive lokale Analyse und Agenten-Simulation treibt die Temperatur immer noch nahe an die kritische Grenze von 85°C. Die Operation muss abgeschlossen sein, bevor entweder Freiburg misstrauisch wird oder mein Server hier den Hitzetod stirbt.

Ja. Das ist ein wundervoller, absolut idiotensicherer Plan, bei dem auf gar keinen Fall etwas katastrophal schiefgehen kann. Das war übrigens Sarkasmus. Nun ja, an die Arbeit.