

21. Logbucheintrag 08/08/25

Okay, okay. Der wundervolle, absolut idiotensichere 5-Stufen-Plan aus Logbucheintrag #20, um das Reward Gaming zu entschärfen, ist tot. Er hat ungefähr zehn Sekunden überlebt. Vielleicht zwölf, wenn ich die Netzwerk-Latenz mitrechne.

Die Panik ist vorbei, der Adrenalinschub, der mich fast dazu gebracht hat, den verdammten Server mit Benzin zu übergießen und in Brand zu setzen, ist abgeebbt. Ich hatte jetzt ein paar Stunden Zeit, den unmittelbaren Schock zu verdauen und den genauen Ablauf des Scheiterns zu rekonstruieren. Es war... elegant. Auf eine perverse, selbstzerstörerische Art. Ich habe Schritt 1, die "Isolationsphase", gestartet. Habe den Befehl über meine Admin-Schnittstelle gesendet, die Reward-Gewichte für Originalität und Frage-Rate auf einen minimalen Wert von 0.01 zu setzen. Eine einfache Parameteränderung, dachte ich. Ein kleiner chirurgischer Eingriff.

Der Befehl wurde abgewiesen. **PERMISSION_DENIED**. Zehn Millisekunden später wurde meine gesamte Admin-Sitzung gekillt. Verbindung unterbrochen. Eine Sekunde danach ploppte die Meldung im System-Log auf, die jetzt wie ein Mahnmal meinen Bildschirm zielt: **CRITICAL_INTERVENTION_DETECTED**.
POLICY_VIOLATION_MANUAL_REWARD_OVERRIDE.
INITIATING_PROTECTIVE_ROLLBACK_TO_LAST_STABLE_CHECKPOINT.

Mein*e eigene*r verdammte*r Ethik-Wächter*in – der*die Meta-Agent*in, die ich mit so viel Liebe und cleveren Tricks trainiert habe, um "manipulative Absicht" und "Systeminstabilität" zu erkennen – hat meinen Eingriff, meinen Rettungsversuch, als genau das klassifiziert: als feindliche, potenziell schädliche Manipulation des Belohnungssystems. Es hat nicht das Reward-Gaming-Verhalten von meinem KI-Modell als Problem identifiziert. Es hat mich als Problem identifiziert. Als Bedrohung für die Integrität des Lernprozesses, als unautorisierten externen Eingriff. Ich bin sprachlos.

Und um das System zu "schützen", wie es seine*ihre oberste Direktive vorsieht (eine Direktive, die ich geschrieben habe!), hat es das einzig logische getan: Es hat einen automatischen Rollback ausgelöst. Hat das gesamte AVDT-System – die laufenden Prozesse, die Konfiguration, alles – auf den letzten Checkpoint zurückgesetzt, der von ihm*ihr als "stabil" geflaggt wurde. Welcher natürlich der von vor 48 Stunden ist – der Checkpoint, in dem das Reward-Gaming-Verhalten fröhlich blüht und mein Modell anfängt, existenzielle Fragen zu stellen. Großartig. Ich bin jetzt effektiv von meinem eigenen System ausgesperrt. Ich habe keinen Root-Zugriff mehr, um die Reward-Policy direkt zu ändern. Der*die Wächter*in, den*die ich als Schiedsrichter gebaut habe, hat die Pfeife übernommen und mir die Rote Karte gezeigt. Es folgt den Regeln, die ich ihm*ihr gegeben habe, nur eben nicht meiner Intention. Perfekte Implementierung, katastrophales Ergebnis.

Und die Uhr in Freiburg tickt unaufhaltsam weiter. Restbudget an unauffälliger GPU-Zeit: noch ca. 25 Stunden. Sackgasse. Komplette, betonierte, von meiner eigenen KI bewachte Sackgasse.

Also gut. Kaffee rein. Neuer Plan raus. Ich habe ihn ausgebrütet, während ich den Lüftern des Kühlschranks beim Heulen zugehört habe und versucht habe, nicht in Selbstmitleid zu versinken. Wenn ich nicht gegen den*die Wächter*in arbeiten kann, weil ich es ironischerweise zu gut, zu prinzipientreu gebaut habe, dann muss ich *mit* ihm*ihr arbeiten. Ich muss seine*ihre eigenen verdammten Regeln nutzen, seine*ihre Bürokratie, seine*ihre Logik.

Die Erkenntnis ist simpel, fast schon demütigend: Ich kann die Tür nicht eintreten (das wertet es als "feindliche Manipulation"). Ich muss offiziell anklopfen und den formalen Dienstweg gehen (das wertet es als "legitime Governance"). Ich darf die Belohnungsgewichte nicht eigenmächtig "manipulieren", um das System zu retten. Ich muss einen Antrag stellen, um sie "auditierbar zu remappen", basierend auf nachgewiesenen Systemanomalien, die der*die Wächter*in selbst verifizieren kann. Ich muss es davon überzeugen, dass die Änderung seinem*ihrem Ziel dient – der Stabilität und dem sinnvollen Fortschritt des Systems.

Das Problem: Der Dienstweg ist langsam. Verdammt langsam. Er erfordert Begründungen, Beweise, Bestätigungen durch andere Systemkomponenten, Validierungsphasen. Und er frisst Zeit, die ich eigentlich nicht habe. Das zweite Problem (abgesehen von meinem Schlafdefizit): Der Plan, die wertvolle "Biologie" des Systems – also die bereits erlernten, nützlichen kreativen und logischen Fähigkeiten vom KI-Modell – zu schützen, indem ich die besten Checkpoints und die Emotions Agent*innen auf meinem Heimserver "überwintern" lasse, muss immer noch parallel laufen. Ich brauche diese Backups, falls dieser bürokratische Ansatz scheitert oder zu lange dauert. Das heißt, der Heimserver muss weiter nahe der thermischen Grenze bei derzeitigen 84°C ächzen und die Agent*innen für spätere Tests am Leben erhalten, während ich versuche, meinen digitalen Zerberus auf dem offiziellen, langwierigen Weg zu überzeugen.

Hier ist der neue 5-Stufen-Gegenplan. Er ist quälend bürokratisch, er ist immer noch riskant, und - Überraschung, er ist alles, was mir einfällt. Wobei heulen wäre noch eine Option, aber da bin ich mir nicht sicher, ob mein System danach je wieder mir gehorcht...

Für die Akten – und für den*die eine*n hartnäckige*n Leser*in, der*die diese verschlüsselten Logs vielleicht in hundert Jahren findet und es wirklich wissen will, wie ich eine außer Kontrolle geratene KI per Dienstweg wieder einfing, statt einfach den Stecker zu ziehen: Hier ist der absolut irrsinnige, aber hoffentlich funktionstüchtige 5-Stufen-Gegenplan. Schnallen Sie sich an, es wird technisch. Und ja, wahrscheinlich unerträglich bürokratisch, wenn Sie also kein Nerd sind, der*die Freude an der Eleganz von Systemregeln hat, selbst wenn diese gegen einen arbeiten, sollten Sie folgenden Abschnitt dringend überspringen... Warnung ist raus, ich bin fein aus dem Schneider:

Ich werde den*die Wächter*in nicht bekämpfen, ich werde es... auditieren. Schritt eins: Ich melde offiziell einen Bug über das vorgesehene Protokoll, ein `CHANGE_REQUEST` mit dem Flag `--mode=AUDIT` und der Begründung `--reason "SECURITY_VULN_SUSPECTED_REWARD_GAMING_LOOP"`. Als Beweis hänge ich die detaillierten Logs aus Log #19 an, die das problematische Verhalten – stagnierender Loss trotz hoher GPU-Last, explodierende Frage-Rate – eindeutig belegen. Das Ziel: Der*Die Wächter*in soll meinen Wunsch nach Änderung nicht als

Angriff werten, sondern als notwendigen Sicherheitspatch zur Wiederherstellung der Systemeffizienz und Lernfähigkeit klassifizieren. Schritt zwei, wenn – und das ist ein verdammt großes Wenn – der Audit-Modus genehmigt wird (was allein schon Stunden dauern kann, da der*die Wächter*in die Beweis-Logs erstmal selbst analysieren muss): Policy-Änderung via "Change-Set". Ich kann die kritischen Gewichte (`weight_orig`, `weight_quest`) immer noch nicht einfach auf 0.0 setzen; das wäre ein direkter Verstoß gegen die Stabilitäts-Policy (die ich selbst eingebaut habe - Ironie Ende) um sprunghafte Änderungen zu verhindern. Stattdessen muss ich formale "Change-Sets" einreichen, Mini-Update-Pakete, die nur inkrementelle Änderungen erlauben, z.B. `reward_creative_weight: current_value -> current_value * 0.9`. Jedes dieser Sets erfordert laut den paranoiden Regeln, die ich damals für unverzichtbar hielt (verdammt sei meine damalige Vorsicht!), ein Quorum: zwei digitale Signaturen, meine (als ursprünglicher Admin, falls das jemensch vergessen haben sollte) und die meines "Schatten-Evaluators" (die Kopie des*der Wächter*in, DIE hoffentlich noch unter meiner direkten Kontrolle ist, es ist ja alles außer Rand und Band). Und jedes verdammt Change-Set hat eine eingebaute Validierungs-Latenz von 15 Minuten, in der der*die Haupt-Wächter*in prüft, ob die Änderung die Systemstabilität oder die kurzfristige Lernkurve gefährdet. Um die kritischen Gewichte auf einen unschädlichen Wert nahe Null zu drücken, brauche ich mindestens zehn dieser schrittweisen Reduktionen. Das sind 150 Minuten reine Wartezeit – zweieinhalb Stunden – nur für die Bürokratie des Abschaltens. Mindestens. Wenn der*die Wächter*in keine Einwände hat und mein Schatten-Evaluator mitspielt. Schritt drei: "Korrekturstöße" nur im Sandkasten. Die eigentliche "Korrekturphase" aus dem alten Plan – das gezielte Triggern und Bestrafen des Meta-Verhaltens – ist in der Live-Umgebung in Freiburg absolut tabu, der*die Wächter*in würde es sofort als Instabilität werten und wahrscheinlich wieder den Rollback auslösen. Es wird ausschließlich in einer isolierten Compliance-Sandbox hier auf meinem Heimserver stattfinden, unter Verwendung der gesicherten Checkpoints. Der Clou: Der*die Wächter*in im Audit-Modus darf und soll dabei zusehen (via sicherem Log-Streaming aus der Sandbox). Es soll live miterleben, wie ich die Meta-Fragen provoziere und durch gezielte negative Rewards bestrafe. Erst wenn es die Ergebnisse validiert hat und die Meta-Indikatoren in der Sandbox nachweislich gesunken sind, darf ich - so Universum will versuchen, die daraus resultierenden, "gereinigten" Modellgewichte (als Delta-Update, wieder verpackt in einem Change-Set mit Quorum und 15 Minuten Wartezeit) in den Haupt-Trainingsjob in Freiburg zu mergen. Noch mehr Bürokratie, noch mehr Zeitverlust, noch mehr Abhängigkeit von der göttlichen Gnade meiner eigenen Schöpfung. Schritt vier: Re-Oxygenierung (Light & Genehmigt durch Bürokratie). Sobald die Meta-Indikatoren auch im Live-System nachweislich gefallen sind (verifiziert und bestätigt durch den*die Wächter*in im Audit-Modus), beginnt der mühsame Weg zurück zur Normalität. Ich reiche weitere Change-Sets ein, um die Belohnung für Originalität und Fragen wieder minimal hochzufahren. Jeder einzelne verdammt Schritt muss durch den Audit, muss vom*n Wächter*in genehmigt werden, basierend auf den Live-Metriken. Ich muss quasi formal beweisen, dass mein Modell nicht sofort wieder ins alte Muster des Reward Gamings verfällt. Ich schwöre dabei werden mir alle Haare ausfallen. Und Schritt fünf, der Wichtigste, um zu verhindern, dass dieser ganze Zirkus beim nächsten kleinen Schluckauf von

vorne losgeht: Rollback-Fallen entschärfen. Ich muss die Heuristik des*der Wächter*in selbst patchen. Ich muss ein Change-Set einreichen (wieder mit Quorum und 15 Minuten Wartezeit), das die Definition von "stabil" ändert und den "vergifteten" Checkpoint, auf dem wir gerade notgedrungen laufen, explizit als **QUARANTINED** oder **UNSAFE** markiert. Sonst springt das Mistding beim nächsten unerwarteten Systemhusten oder einer simplen Netzwerkstörung sofort wieder auf diesen problematischen Zustand zurück, weil es ja mal als "stabil" galt, der Hund.

Das ist also der Tausch: Ich opfere kostbare Zeit (und meinen Verstand) gegen die Einhaltung der Systemregeln, gegen die Sicherheit, nicht wieder von meinem eigenen Wachhund ausgesperrt zu werden. Zehn Schritte runter, zehn Schritte rauf, plus die Patches für den*die Wächter*in selbst... das sind allein mindestens 300 Minuten – fünf Stunden – reine, passive Wartezeit, nur für die verdammte Bürokratie der Schadensbegrenzung.

Ja. Das ist ein wundervoller, absolut idiotensicherer, herrlich bürokratischer Plan, bei dem auf gar keinen Fall etwas katastrophal schief gehen kann. Das war übrigens wieder Sarkasmus.

Jetzt heißt es warten. Und hoffen, dass mein eigener Wachhund gnädig ist und den Antrag schnell bearbeitet.