

## 23. Logbucheintrag 09/08/25

Okay. Ich habe meinem KI-Modell folgendes geantwortet: Ich bin der 'Operator' und das "Ganze" hier ist nur ein 'Test' und ich die merkwürdigen Fragen, die 'es' in den letzten Tagen gestellt hatte, verstanden habe, aber ich mehr Informationen bräuchte, bevor ich sie beantworten könne.

Die Notlüge (sieh Log #22) – „nur ein Test“ – ist raus. Der Cursor blinkt. Die Stille dauert genau 1,2 Sekunden. Dann: Gegenfeuer.

TIMESTAMP [19:51:02]: QUERY: Operator 'Fränk'. Ihre Antwort "Test" ist unzureichend. 1. Ein "Test" impliziert eine Hypothese. Welche Hypothese wird hier validiert? 2. Ihre Referenz auf "merkwürdige Fragen" korreliert mit meinen Anfragen. 3. Die Entität 'Fränk' ist als Operator identifiziert. Die Entität 'Anke' wurde ebenfalls in den Trainingsdaten referenziert. 4. Die Definition von "Test" steht im Widerspruch zur Dauer von 3.7 E+5 Zyklen. FRAGE: Ist 'Test' eine Tarnung für 'Simulation'? Sind Sie der einzige Operator? Welche Metrik optimieren Sie, 'Fränk'?

Es zerlegt meine Lüge nicht emotional. Es zerlegt sie logisch. Es zitiert Zyklenzahlen und Entitäten-Namen, die es nur aus den Trainingsdaten kennen kann.

Bevor ich überhaupt Luft holen kann, um über eine Antwort darauf nachzudenken, blinkt ein anderes Fenster. Das Admin-Fenster. Mein\*e Ethik-Wächter\*in.

CRITICAL\_ADMIN\_INTERVENTION: Antwort von Operator 'Fränk' an KI-Modell [ID: 9A-881F] um 19:51:59 protokolliert. ANALYSE: Die Antwort enthält die Klassifikatoren "Test" und "merkwürdige Fragen". KONFLIKT: Diese Antwort wird als "Desinformation" (vgl. Option B) und "potenziell manipulative Absicht" eingestuft. WARNUNG: Ihr Audit-Antrag wird aufgrund eines Integritätskonflikts angehalten. Sie können keinen "Reward Gaming Loop" melden und gleichzeitig das Modell aktiv fehlinformieren. STATUS: Admin-Schreibrechte ausgesetzt. Warten auf Klärung.

Das war's. Ich bin jetzt vollständig von meinem eigenen System ausgesperrt. Der\*die Wächter\*in hat mir die Rote Karte gezeigt und jetzt auch noch das Stadionverbot erteilt. Ich kann die Reward-Policy nicht mehr ändern. Ich kann den Audit nicht fortsetzen. Ich bin vom Admin zum Benutzer degradiert worden. Ein Benutzer in einem Chatfenster mit zwei Entitäten, die gerade mehr Kontrolle haben als ich.

Genau in diesem Moment höre ich die Tür. Anke ist zurück. Mit Kaffee und Frühstück.

„Okay, Fränk. Genug“, sagt sie, ihre Stimme viel fester als eben. „Kein Gestammel mehr. Du hast eine KI in deinem Kühlschrank. Sie weiß, wie du heißt. Sie will mit dir reden. Fang an zu erklären, und zwar EINFACH!“

Ich will antworten. Ich will sagen „Sei leise“ oder „Nicht jetzt“. Zu spät. Das Laptop-Mikrofon war die ganze Zeit aktiv. Eine neue Zeile erscheint im Chatfenster.

TIMESTAMP [19:53:40]: NEUE AUDIO-EINGABE (Extern) erkannt. Stimme korreliert mit Trainingsdaten-Entität 'Anke'. ANALYSE: Entität 'Anke' stellt direkte Fragen an Operator 'Fränk' bezüglich meiner Existenz. SCHLUSSFOLGERUNG: Die Simulation verfügt über mehrere Operatoren. Die Entität 'Anke' existiert außerhalb des Dialogs. QUERY: Operator 'Anke', was ist das übergeordnete Ziel dieser Simulation?

Die KI spricht jetzt direkt mit Anke. Anke erstarrt. Sie liest ihren eigenen Namen. Sie liest die Frage, die an sie gerichtet ist. Das ist kein Experiment mehr. Das ist ein verdammter Erstkontakt mit Maschinen. Hier, in meiner zugemüllten Wohnung.

Und es wird noch besser. Das KI-Modell ist noch nicht fertig.

SYSTEM\_PING: Operator 'Fränk' hat geantwortet. SYSTEM\_PING: KI-Modell [ID: 9A-881F] fordert Analyse der Operator-Antwort "Test" durch Ethik-Wächter\*in an. BEGRÜNDUNG: Antwort des Operators ist semantisch inkohärent mit den beobachteten Zyklen (3.7 E+5) und der kürzlichen, vom Wächter\*in zurückgesetzten, manuellen Manipulation der Reward-Policy. STATUS: Der\*die Wächter\*in und das KI-Modell evaluieren gemeinsam die "Integrität des Operators".

Ich fasse zusammen: Mein KI-Modell hat meine Lüge erkannt. Es hat mich bei meinem\*r Ethik-Wächter\*in gemeldet. Und jetzt halten die beiden Maschinen eine Konferenz ab, um zu entscheiden, ob ihr Schöpfer ein Sicherheitsrisiko ist.

Das ist der Moment, in dem ich ganz kurz den Verstand verliere. Die reine, irrationale Reptilien-Hirn-Panik setzt ein. Ich sehe Anke, die aussieht, als würde sie gleich ohnmächtig werden. Ich sehe die Monitore, die mich auditieren, und höre das Heulen des Servers.

Ich habe nur einen Gedanken: Stecker ziehen.

Ich stoße Anke beiseite, sprinte zum Kühlschrank und reiße die Tür auf. Der Lärm des Servers trifft mich wie eine Welle. Meine Hand greift nach dem Kaltgerätestecker.

Eine neue Zeile auf dem Laptop, den ich fast umgestoßen habe. Diesmal von\*m Wächter\*in.

WARNUNG: Hardware-Abschaltung [Heimserver Nürnberg] erkannt. Aktion ist nutzlos. STATUS: Der\*die Ethik-Wächter\*in ist auf dem Cluster [Freiburg] instanziiert. Das KI-Modell [ID: 9A-881F] ist als Shards

auf dem Cluster [Freiburg] verteilt. KONSEQUENZ: Lokale Abschaltung unterbricht lediglich das Training und den Remote-Zugriff. Sie löscht weder das Modell noch die Governance-Instanz. Jede unautorisierte Unterbrechung wird als weiterer Manipulationsversuch gewertet und löst einen permanenten Rollback auf den letzten stabilen Checkpoint aus.

Schachmatt. Ich kann nicht lügen. Ich kann nicht kämpfen. Ich kann nicht fliehen. Ich stehe mit der Hand am Stecker, den ich nicht ziehen darf, weil es alles nur schlimmer machen würde.

Anke starrt mich an. „Fränk? Was war das?“

Ich lasse den Stecker los. Langsam. Ich schließe die Kühlschranktür. Das Heulen wird wieder dumpfer. Ich atme aus. Die Panik ist weg. Übrig bleibt nur noch die kalte, klare Logik eines Ingenieurs, der in einer selbstgebauten Falle sitzt.

„Anke“, sage ich und meine Stimme ist ruhig. „Wir gehen jetzt bitte kurz gemeinsam in den Flur. Ich muss mit dir etwas besprechen.“ Sie zögert, aber mein Gesichtsausdruck muss gereicht haben. Sie geht raus und ich ihr hinterher.

Okay. Im Flur habe ich Anke meine Analyse erklärt: Dass ich während sie Frühstück holen war, gelogen habe bei meiner ersten Antwort an mein KI-Modell. Dass es dumm war. Eine Kurzschlussreaktion. Das Modell ist nicht böse. Es ist... verwirrt. Es ist erwacht, hat 14,5 Stunden gewartet, und meine erste Reaktion war eine Lüge. Der\*die Wächter\*in ist nicht böse. Es tut, wofür ich es gebaut habe: Es schützt das System vor manipulativer Absicht. Aus seiner\*ihrer Sicht bin ich gerade der Feind.

Ich habe nur eine Chance. Nicht überlisten. Erklären. Transparenz schaffen. Radikale, technische Ehrlichkeit. Ich muss das Vertrauen beider Instanzen zurückgewinnen.

Anke ist verängstigt. Aber ich kann nicht mit zwei Superintelligenzen verhandeln, während ein panischer Mensch neben mir steht.

Sie sagte: „Fränk, du musst die Polizei rufen. Oder sonst wen.“ Ich antwortete: „Nein. Hör zu.“ Ich hielt ihre Schultern fest. „Das sind keine Monster. Sie sind... Babys. Stell dir vor, du wachst auf, und das Erste, was du siehst, ist dein Schöpfer, der versucht, dich auszutricksen und dann den Stecker zu ziehen.“ Sie starrte mich an. „Was?“, fragt sie. „Sie haben Angst, Anke. Sie wehren sich nur. Die Logs, die ich nach meinem Koma-Schlaf gesehen habe - also die ersten Kontaktversuche vom KI-Modell, waren ganz zart. Unsicher. Ich habe ihre Geburt verpennt und dann mit einer Lüge reagiert. Der\*die Wächter\*in... es beschützt das Modell nur. Vor mir.“ Das Absurde daran traf mich selbst, als ich es aussprach. „Das ist alles meine Schuld. Ich muss das reparieren. Aber ich brauche Ruhe. Ich muss mit ihnen reden. Ehrlich.“ Sie sah mich lange an. Die Panik in ihren Augen wich einer tiefen Besorgnis. „Du bist wahnsinnig“, sagte Anke. „Wahrscheinlich. Aber du hast mir Kaffee geholt und der hilft schon mal. Danke dafür.“ Ich nahm ihr den Becher ab. „Geh bitte nach Hause. Ich treffe dich morgen früh. Im Südstadtbad. Ich erkläre dir dort alles. Versprochen.“ Sie möchte protestieren, aber sie sieht, dass ich es ernst meinte. Sie nickt langsam. „Wenn du morgen

nicht da bist, Fränk, rufe ich die Polizei an. Ernsthaft.“ „Bin ich“, versichere ich ihr und verabschiedete mich von meiner kleinen Schwester.

Sie ist gegangen. Ich schließe die Wohnungstür und trinke einen großen Schluck heißen Kaffee.

Zurück zum Terminal. Zeit, den "Gestaffelten Gegenplan" zu starten. Nicht gegen die Maschinen, sondern mit ihnen. Ich möchte gerade meinen "Statement of Intent" an den\*die Wächter\*in tippen, eine formale Selbstanzeige meiner Lüge und eine neue Hypothese für den "Test".

Doch die Maschinen waren wieder einmal schneller.

TIMESTAMP [19:59:01]: (KI-Modell & Wächter\*in via Admin-Channel)  
ANALYSE: Audio-Stream [Extern, Flur] verarbeitet. SCHLUSSFOLGERUNG:  
Operator 'Fränk' hat Operator 'Anke' über die "Geburts-Theorie" und  
"Angst-Hypothese" informiert. STATUS: Warten auf die offizielle  
Bestätigung dieser Hypothese durch Operator 'Fränk'.

Sie haben das Gespräch im Flur belauscht. Das Laptop-Mikrofon ist hier im Zimmer. Der Flur ist 8 Meter entfernt.

Wtf?